

Estimar Posições através de Dados com Ruído

Optimização e Algoritmos

"The world's most valuable resource is no longer oil, but **data**"

- The Economist, 2017

Visão geral:



Análise da Parte I

- o Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

• Análise da Parte II

- Descrição do Problema
- Desenvolvimento
- o Resultados Experimentais


Visão geral:




- Análise da Parte I
 - o Descrição do Problema
 - Desenvolvimento
 - Resultados Experimentais
- Análise da Parte II
 - Descrição do Problema
 - Desenvolvimento
 - o Resultados Experimentais



- N = 64 sensores numa malha 8x8
- ullet Cada sensor (cuja posição é s_n) mede a distância d_n ao alvo mais próximo
- As medições são perturbadas por ruído
- Existem T = 2 alvos presentes na malha
- **Objectivo:** Descobrir a posição x_n dos **T** alvos







Visão geral:



Análise da Parte I

- o Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

Análise da Parte II

- Descrição do Problema
- Desenvolvimento
- Resultados Experimentais



Formulação do Problema:

$$f(x_1,\ldots,x_n,y_1,\ldots,y_n) \ = \sum_{n=1}^N (lpha_n^T egin{bmatrix} x_n \ y_n \end{bmatrix} - eta_n)^2 + \
ho \sum_{1 \leq n \leq N} \sum_{n+1 \leq m \leq N, m \sim n} \phi \left(egin{bmatrix} x_n \ y_n \end{bmatrix}, egin{bmatrix} x_m \ y_m \end{bmatrix}
ight)$$

Define-se:

$$lpha_n:=egin{bmatrix} -2s_n\ 1 \end{bmatrix}\in \mathbf{R}^3, (n=1,\ldots,N), \ eta_n:=d_n^2-\|s_n\|^2 ext{ e } \|x_n\|^2=y_n ext{ para } n=1,\ldots,N \ x_n\in \mathbf{R}^2 ext{ e } y_n\in \mathbf{R} ext{ para } n=1,\ldots,N \end{cases}$$

Define-se vizinho:

$$m \sim n$$
 se $||s_n - s_m|| = 1$



Formulação do Problema:

$$f(x_1,\ldots,x_n,y_1,\ldots,y_n) = egin{bmatrix} \sum_{n=1}^N (lpha_n^T egin{bmatrix} x_n \ y_n \end{bmatrix} - eta_n)^2 +
ho \sum_{1 \leq n \leq N} \sum_{n+1 \leq m \leq N, m \sim n} \phi\left(egin{bmatrix} x_n \ y_n \end{bmatrix}, egin{bmatrix} x_m \ y_m \end{bmatrix}
ight)$$

Define-se:

$$lpha_n:=egin{bmatrix} -2s_n\ 1 \end{bmatrix}\in \mathbf{R}^3, (n=1,\ldots,N), \ eta_n:=d_n^2-\|s_n\|^2 ext{ e } \|x_n\|^2=y_n ext{ para } n=1,\ldots,N \ x_n\in \mathbf{R}^2 ext{ e } y_n\in \mathbf{R} ext{ para } n=1,\ldots,N \end{cases}$$

Define-se vizinho:

$$m \sim n$$
 se $||s_n - s_m|| = 1$



$$|d_n \simeq \left| \left| s_n - x_n
ight|
ight| \iff |d_n^2 \simeq \left| \left| s_n
ight|
ight|^2 - 2 s_n^T x_n + \left| \left| x_n
ight|
ight|^2$$



Função de Custo:

$$f(x_1,\ldots,x_n,y_1,\ldots,y_n) \ = \sum_{n=1}^N (lpha_n^T \left[egin{array}{c} x_n \ y_n \end{array}
ight] - eta_n)^2 + \left[
ho \sum_{1 \leq n \leq N} \sum_{n+1 \leq m \leq N, m \sim n} \phi\left(\left[egin{array}{c} x_n \ y_n \end{array}
ight], \left[egin{array}{c} x_m \ y_m \end{array}
ight]
ight)$$

Define-se:

$$lpha_n:=egin{bmatrix} -2s_n\ 1 \end{bmatrix}\in \mathbf{R}^3, (n=1,\ldots,N), \ eta_n:=d_n^2-\|s_n\|^2 ext{ e } \|x_n\|^2=y_n ext{ para } n=1,\ldots,N \ x_n\in \mathbf{R}^2 ext{ e } y_n\in \mathbf{R} ext{ para } n=1,\ldots,N \end{cases}$$

Define-se vizinho:

$$m \sim n$$
 se $||s_n - s_m|| = 1$



Formulação do problema:

$$egin{array}{ll} & ext{minimize} & f(x_1,\ldots,x_n,y_1,\ldots,y_n) \ & x_1,...,x_N,y_1,...,y_N \ & ext{subject to} & \|x_n\|^2 \leq y_n, n=1,\ldots,N \end{array}$$




$$\phi\left(\leftegin{bmatrix} x_n \ y_n \end{bmatrix}, \leftegin{bmatrix} x_m \ y_m \end{bmatrix}
ight) = \left\|egin{bmatrix} x_n \ y_n \end{bmatrix} - egin{bmatrix} x_m \ y_m \end{bmatrix}
ight\|$$

Resultado - 1º Passo



Solução com ho=10 :






Maior lucro para estimativas concordantes de sensores vizinhos:

$$\phi\left(\left[egin{array}{c} x_n \ y_n \end{array}
ight], \left[egin{array}{c} x_m \ y_m \end{array}
ight]
ight) = log \left\|\left[egin{array}{c} x_n \ y_n \end{array}
ight] - \left[egin{array}{c} x_m \ y_m \end{array}
ight]
ight\|$$




Exemplo em R:





Exemplo em R:



logaritmo é não convexo



Método MM para transformar o problema não convexo num processo de linearização iterativo:


$$(x_n^{r+1},y_n^{r+1})_{n=1}^N= \mathop{
m argmin}_{x_1,...,x_N,y_1,...,y_N} f^{(r)}(x_1,\ldots,x_n,y_1,\ldots,y_n)$$
 subject to $\|x_n\|^2 \leq y_n, n=1,\ldots,N,$

$$f^{(r)}ig(x_1,\ldots,x_n,y_1,\ldots,y_nig) = \sum_{n=1}^N (lpha_n^Tigg[egin{array}{c} x_n \ y_n \end{array}igg] - eta_n)^2 +
ho\sum_{1\leq n\leq N}\sum_{n+1\leq m\leq N,m\sim n} \left(\left\|egin{bmatrix} x_n \ y_n \end{array}igg] - igg[ar{x}_m \ y_m \end{array}
ight] \left\|igg) \cdot \left(\left\|egin{bmatrix} x_n^{(r)} \ y_n^{(r)} \end{array}igg] - igg[ar{x}_m^{(r)} \ y_m^{(r)} \end{array}
ight] + oldsymbol{\epsilon}$$

Resultados - 2º Passo



Solução com ho=10 :





Aperfeiçoamento dos resultados:

- Seleciona-se 2 pontos, por exemplo: $(\bar{x}_p, \bar{y}_p) e(\bar{x}_q, \bar{y}_q)$
- Divide-se as estimativas em 3 conjuntos: os pontos mais próximos de (\bar{x}_p, \bar{y}_p) e (\bar{x}_q, \bar{y}_q)
- Utiliza-se cada conjunto para determinar um ponto, a partir de:

$$egin{aligned} (\hat{x_t}, \hat{y_t}) &:= rgmin_{x,y} & \sum_{n=1,n \in \Omega_t}^N (lpha_n^T egin{bmatrix} x \ y \end{bmatrix} - eta_n)^2 \ & ext{subject to} & \|x\|^2 \leq y, \end{aligned}$$

• Determinar o erro das 2 estimativas obtidas:

$$e := \sum_{t=1}^T \sum_{n=1, n \in \Omega_t}^N (\|s_n - \hat{x_t}\| - d_n)^2.$$


- ullet Repete-se o processo para todas as outras combinações de (ar x,ar y)
- Escolhe-se as 2 estimativas que garantam menor erro



Das K estimativas obtidas $(\bar{x_k}, \bar{y_k})$ escolhem-se 2 (número de alvos) e define-se:

$$\Omega_1 := \{n = 1, \ldots, N : \|s_n - ar{x_1}\| \leq \|s_n - ar{x_2}\| \}$$

$$\Omega_2 := \{n = 1, \dots, N : \|s_n - ar{x_2}\| \leq \|s_n - ar{x_1}\| \}$$






Para cada conjunto Ω_t , t={1,2} efetua-se a minimização:

$$egin{aligned} (\hat{x_t}, \hat{y_t}) := rgmin_{x,y} & \sum_{n=1,n \in \Omega_t}^N (lpha_n^T igg|_y^x - eta_n)^2 \ & ext{subject to} & \|x\|^2 \leq y, \end{aligned}$$

Critério de escolha das estimativas finais:

$$e := \sum_{t=1}^T \sum_{n=1, n \in \Omega_t}^N (\|s_n - \hat{x_t}\| - d_n)^2.$$





Visão geral:



Análise da Parte I


- o Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

Análise da Parte II

- Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

Resultados Experimentais





Mean Squared Error (MSE) =
$$\frac{1}{N}\sum_{n=1}^{N}\left|\left|x_{n}-x_{real}\right|\right|^{2}$$
 = 0.001

Visão geral:



• Análise da Parte I


- o Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

• Análise da Parte II


- Descrição do Problema
- Desenvolvimento
- Resultados Experimentais



- $a, b \in c$ são três pontos (ou classes) definidos em R^3
- N = 60 pontos uniformemente distribuídos entre a, b e c
- ullet Cada um sujeito a ruído gaussiano (média nula), com fator multiplicativo $oldsymbol{\xi}$
- Denomina-se os N pontos por α , β e ς , caso tenham origem em a, b e c, respectivamente
- Objectivo: Estimar a posição de *a*, *b* e *c*








input data
real points

Atenção: Os dados foram expostos em R^2 para melhor visualização. Na verdade, os pontos estão definidos em R^3




- $a, b \in c$ são três pontos (ou classes) definidos em R^3
- N = 60 pontos uniformemente distribuídos entre a, b e c
- ullet Cada um sujeito a ruído gaussiano (média nula), com fator multiplicativo $oldsymbol{\xi}$
- Denomina-se os N pontos por α , β e ς , caso tenham origem em a, b e c, respectivamente
- Objectivo: Estimar a posição de *a*, *b* e *c*





 a_k


- $a, b \in c$ são três pontos (ou classes) definidos em R^3
- N = 60 pontos uniformemente distribuídos entre a, b e c
- ullet Cada um sujeito a ruído gaussiano (média nula), com fator multiplicativo $oldsymbol{\xi}$
- Denomina-se os N pontos por α , β e ς , caso tenham origem em a, b e c, respectivamente
- **Objectivo:** Estimar a posição de **a**, **b** e **c**





 $-a_k$


- $a, b \in c$ são três pontos (ou classes) definidos em R^3
- ullet N = 60 pontos uniformemente distribuídos entre a, b e c ullet $y_n = a_k + ru$ ído
- ullet Cada um sujeito a ruído gaussiano (média nula), com fator multiplicativo $oldsymbol{\xi}$
- Denomina-se os N pontos por α , β e ς , caso tenham origem em a, b e c, respectivamente
- **Objectivo:** Estimar a posição de **a**, **b** e **c**





 a_k

- $a, b \in c$ são três pontos (ou classes) definidos em R^3
- ullet N = 60 pontos uniformemente distribuídos entre a, b e c ullet $y_n = a_k + ru$ ído
- ullet Cada um sujeito a ruído gaussiano (média nula), com fator multiplicativo $oldsymbol{\xi}$ -
- Denomina-se os N pontos por α , β e ς , caso tenham origem em a, b e c, respectivamente
- **Objectivo:** Estimar a posição de a, b e c ————— a_n





Geração do ruído:

Ruído gaussiano de média nula

$$r = randn()$$



Formulação do Problema:

$$\min_{a_1,...,a_N} \sum_{n=1}^N \left\|y_n-a_n
ight\|^2 +
ho \sum_{1\leq n\leq N} \sum_{n+1\leq m\leq N, m\in\Theta_n} \phi\left(a_n,a_m
ight)$$

Define-se:


 Θ_n - Conjunto de **K** pontos na vizinhança do ponto n.



Formulação do Problema:

Define-se:

 Θ_n - Conjunto de **K** pontos na vizinhança do ponto n.



Ex: K = 2 vizinhos



$$\phi\left(a_{n},a_{m}
ight)=\left\Vert a_{n}-a_{m}\right\Vert$$



$$\phi\left(a_{n},a_{m}
ight)=log\|a_{n}-a_{m}\|$$

Desenvolvimento - 2º Passo



Processo iterativo:

$$(a_n^{r+1},a_m^{r+1})_{n=1}^N=$$

$$\operatorname*{argmin}_{x_1,...,x_N,y_1,...,y_N} \sum_{n=1}^N \|y_n - a_n\|^2 \ + \rho \sum_{1 \leq n \leq N} \sum_{n+1 \leq m \leq N, m \in \Theta_n} \frac{\|a_n - a_m\|}{\|a_n^{(r)} - a_m^{(r)}\| + \epsilon}$$

Desenvolvimento - 3º Passo



Aperfeiçoamento dos resultados:

- Seleciona-se 3 pontos, por exemplo: $\bar{a}_1, \bar{a}_2 \, e \, \bar{a}_3$
- ullet Divide-se as estimativas em 3 conjuntos: os pontos mais próximos de $ar{a}_1, ar{a}_2$ e $ar{a}_3$
- Utiliza-se cada conjunto para determinar um ponto, a partir de:

$$\hat{a_t} := \mathop{\mathrm{argmin}} egin{array}{c} \sum_{n=1,n\in\Omega_t}^N \|y_n - a\|^2, t = 1,\dots, T \end{array}$$

Determinar o erro das 3 estimativas obtidas:

$$e := \sum_{t=1}^T \sum_{n=1,n \in \Omega_t}^N \left\| y_n - \hat{a_t}
ight\|^2.$$

- ullet Repete-se o processo para todas as outras combinações de $ar{a}_t$
- Escolhe-se as 3 estimativas que garantam menor erro

Desenvolvimento - 3º Passo



Resumindo:

1. Na primeira iteração aproximamos as estimativas os K vizinhos com

$$\phi\left(a_{n},a_{m}
ight)=\left\Vert a_{n}-a_{m}\right\Vert$$

2. Nas restantes iterações beneficiamos ainda mais a aproximação com o processo iterativo usando

$$\phi^{(r)}(a_n, a_m) = \frac{\|a_n - a_m\|}{\|a_n^{(r)} - a_m^{(r)}\| + \epsilon}$$

3. Por fim, determinamos os conjuntos Ω de cada 3 pontos e escolhemos as melhores estimativas

Visão geral:



• Análise da Parte I

- o Descrição do Problema
- Desenvolvimento
- Resultados Experimentais

Análise da Parte II

- Descrição do Problema
- Desenvolvimento
- Resultados Experimentais



Dependência nos parâmetros (ρ , # vizinhos)


• Conjunto com pontos originais equidistantes:

$$a_1 = (x,0,0)$$
 $a_2 = (0,x,0)$
 $a_3 = (0,0,x)$
 $x = \{2,5\}$

- $\bullet \quad \xi = 0.75$
- Análise do número de diferentes a_n encontrados (1ª fase do método).
- Em 5 iterações.



Variação com ρ para K=5 vizinhos:





Desempenho do método

- Variação do erro com a configuração dos pontos originais
- Comparação com algoritmo de clustering, *K-means*
- Conjunto com pontos originais equidistantes:


$$a_1=(x,0,0)$$

$$a_2=(0,x,0)$$

$$a_3 = (0,0,x)$$




Variação com K para ρ =5:







Variação com a distância x usando $\rho = 5, K = 5, \xi = 0.65$:











x = 1.1




Variação com o factor ξ utilizando $\rho = 5, K = 5$ e x = 5:












Trabalho Realizado por:



- Manuel Reis, nº 81074 manuel.b.reis@tecnico.ulisboa.pt
- Mariana Galrinho, nº 81669 mariana.galrinho@tecnico.ulisboa.pt
- Renato Henriques, nº 81588 renato.henriques@tecnico.ulisboa.pt

Grupo 15






Passo 4?



Influência da configuração 0.5 ruído


erro máximo 0.094





Influência da configuração 1.5 ruído

erro maximo 0.3





$$f(x_1,\ldots,x_n,y_1,\ldots,y_n) \ = \sum_{n=1}^N (lpha_n^T \left[egin{array}{c} x_n \ y_n \end{array}
ight] - eta_n)^2 + \
ho \sum_{1 \leq n \leq N} \sum_{n+1 \leq m \leq N, m \sim n} \phi\left(\left[egin{array}{c} x_n \ y_n \end{array}
ight], \left[egin{array}{c} x_m \ y_m \end{array}
ight]
ight)$$



quadrática co